

Gabarito da Lista de Exercícios 2 de Análise Numérica

Prof.: Fabrício Murai

Informações importantes:

- Data de entrega: até 23:59 do dia 05/04/2018.
- Questões podem ser discutidas entre até três alunos. Nomes dos colegas precisam ser listados. Contudo, a escrita das soluções e submissão deve ser feita individualmente.
- Submissão deve ser feita em formato PDF através do Moodle, mesmo que tenham sido resolvidas a mão e escaneadas.
- Todas as soluções devem ser justificadas.
- Se puder, peço por favor que marque o tempo gasto para resolver a lista, para que o tamanho da lista de exercícios seja ajustado em semestres futuros.

1. Considere o sistema linear $Ax = b$, onde a matriz $A = \begin{bmatrix} 9 & 18 \\ 18 & 52 \end{bmatrix}$ é simétrica e definida positiva. Sendo

$b = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$, encontre a solução usando a Decomposição de Cholesky.

A matriz L pode ser obtida utilizando as fórmulas:

$$l_{jj} = \sqrt{a_{jj} - \sum_{k=1}^{j-1} l_{jk}^2}, \quad j = 1, 2, \dots, n.$$

$$l_{ij} = \frac{a_{ij} - \sum_{k=1}^{j-1} l_{ik} l_{jk}}{l_{jj}}, \quad j = 1, 2, \dots, n \text{ e } i = j+1, j+2, \dots, n.$$

Temos então

Coluna 1: $l_{11} = \sqrt{a_{11}} = \sqrt{9} = 3$, $l_{21} = \frac{a_{21}}{l_{11}} = \frac{18}{3} = 6$

Coluna 2: $l_{22} = \sqrt{a_{22} - l_{21}^2} = \sqrt{52 - 6^2} = \sqrt{16} = 4$

Esses resultados podem ser observados no dispositivo prático abaixo

A			L		
i\j	1	2	i\j	1	2
1	9	18	1		
2	18	52	2		

⇓

A			L		
i\j	1	2	i\j	1	2
1	9	18	1	3	
2	18	52	2	6	

⇓

A			L		
i\j	1	2	i\j	1	2
1	9	18	1	3	
2	18	52	2	6	4

Resolvendo o sistema $Ly = b$ pelas substituições sucessivas

$$\begin{bmatrix} 3 & 0 \\ 6 & 4 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 3 \\ 4 \end{bmatrix} \rightarrow y = \begin{bmatrix} 1 \\ -\frac{1}{2} \end{bmatrix}$$

Resolvendo o sistema $L^T x = y$ pelas substituições retroativas

$$\begin{bmatrix} 3 & 6 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} \frac{1}{12} \\ -\frac{1}{2} \end{bmatrix} \rightarrow x = \begin{bmatrix} \frac{7}{12} \\ -\frac{1}{8} \end{bmatrix}$$

2. Refinamento de solução baseado na matriz A anterior.

(a) Para $b = \begin{bmatrix} 3 \\ 4 \end{bmatrix}$, calcule o erro residual ($r = b - Ax$) da solução aproximada dada por $x^{(0)} = \begin{bmatrix} 0,5 \\ -0,1 \end{bmatrix}$.

$$r^{(0)} = \begin{pmatrix} 3 \\ 4 \end{pmatrix} - \begin{pmatrix} 9 & 18 \\ 18 & 52 \end{pmatrix} \begin{pmatrix} 0,5 \\ -0,1 \end{pmatrix} = \begin{pmatrix} 0,3 \\ 0,2 \end{pmatrix}.$$

(b) Use r para executar um refinamento da solução $x^{(0)}$.

Para encontrar a nova aproximação $x^{(1)} = x^{(0)} + c^{(0)}$, basta resolver $Ac^{(0)} = r^{(0)}$. Usando a fatoração Cholesky obtida na questão anterior, temos

$$Ly = r_0 \rightarrow \begin{bmatrix} 3 & 0 \\ 6 & 4 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \end{bmatrix} = \begin{bmatrix} 0,3 \\ 0,2 \end{bmatrix}$$

Resolvendo pelas substituições sucessivas, $y = \begin{bmatrix} 0,1 \\ -0,1 \end{bmatrix}$. Em seguida, resolvemos

$$L^T c^{(0)} = y \rightarrow \begin{bmatrix} 3 & 6 \\ 0 & 4 \end{bmatrix} \begin{bmatrix} c_1 \\ c_2 \end{bmatrix} = \begin{bmatrix} 0,1 \\ -0,1 \end{bmatrix},$$

através das substituições retroativas, obtendo $c^{(0)} = \begin{bmatrix} 0,0833 \\ -0,025 \end{bmatrix}$.

$$\text{Logo, } x^{(1)} = x^{(0)} + c^{(0)} = \begin{bmatrix} 0,5833 \\ -0,125 \end{bmatrix}.$$

3. Assinale **V** para verdadeiro ou **F** para falso e **justifique**:

() A decomposição de Cholesky pode ser aplicada a qualquer matriz $A^T A$ tal que as entradas de A são números reais.

Verdadeiro. Toda matriz $A^T A$ é semidefinida positiva e, portanto, simétrica. Não é necessário provar, mas a demonstração pode ser obtida pela forma quadrática $v^T A^T A v = (Av)^T Av = (Av)(Av) \geq 0$.

() A fatoração LU de uma matriz quadrada A de posto n pode resultar em uma matriz U com linhas nulas.

Falso. A obtenção de uma linha nula em U só pode acontecer se esta for uma combinação linear de outras linhas. No entanto, como o posto(A) = n , sabemos que A possui n linhas linearmente independentes.

() A fatoração LU é aproximadamente duas vezes mais demorada que a fatoração Cholesky, mas ambas requerem o mesmo espaço em memória.

Falso. A primeira parte da sentença é verdadeira, mas o custo de memória da fatoração Cholesky é aproximadamente metade do custo para armazenar as matrizes LU.

4. Dada a matriz $A = \begin{bmatrix} 3 & 0 & 2 \\ 9 & 1 & 7 \\ 1 & 0 & 1 \end{bmatrix}$ e sua inversa $A^{-1} = \begin{bmatrix} 1 & 0 & -2 \\ -2 & 1 & -3 \\ -1 & 0 & 3 \end{bmatrix}$, calcule o número de condicionamento segundos à

(a) Norma-1. É bem condicionado?

$$\|A\|_1 = \max_{1 \leq j \leq 3} \sum_{i=1}^3 |a_{ij}| = \max(13, 1, 10) = 13$$

$$\|A^{-1}\|_1 = \max_{1 \leq j \leq 3} \sum_{i=1}^3 |a_{ij}| = \max(4, 1, 8) = 8$$

$$\kappa_1(A) = \|A\|_1 \|A^{-1}\|_1 = 13 \times 8 = 104$$

$\kappa_1(A) \gg 1$ portanto é mal condicionado.

(b) Norma-infinito. É bem condicionado?

$$\|A\|_\infty = \max_{1 \leq i \leq 3} \sum_{j=1}^3 |a_{ij}| = \max(5, 17, 2) = 17$$

$$\|A^{-1}\|_\infty = \max_{1 \leq i \leq 3} \sum_{j=1}^3 |a_{ij}| = \max(3, 6, 4) = 6$$

$$\kappa_\infty(A) = \|A\|_\infty \|A^{-1}\|_\infty = 17 \times 6 = 102$$

$\kappa_\infty(A) \gg 1$ portanto é mal condicionado.

OBS: é válido lembrar que o número de condicionamento varia com a norma utilizada. Isso pôde ser observado nas duas letras anteriores, obtivemos 2 números de condicionamento diferentes para a mesma matriz A .

(c) Considere um erro na medição do vetor $b = \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$, resultando no vetor $b' = \begin{bmatrix} 1,1 \\ 1,9 \\ 3,0 \end{bmatrix}$. Usando o

número de condição calculado a partir da norma-infinito, determine o limite superior do erro da aproximação encontrada ao se resolver $Ax = b'$.

$$\text{Temos que } \delta b = b' - b = \begin{bmatrix} 1,1 \\ 1,9 \\ 3 \end{bmatrix} - \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix} = \begin{bmatrix} 0,1 \\ -0,1 \\ 0 \end{bmatrix}$$

A fórmula utilizada para calcular o limite superior do erro é dada por:

$$\frac{\|\delta x\|}{\|x\|} \leq \kappa(A) \frac{\|\delta b\|}{\|b\|}, \text{ e usaremos } \kappa_\infty(A) \text{ calculado no item anterior.}$$

$$\kappa_\infty = 102, \|b\|_\infty = 3, \|\delta b\|_\infty = 0,1$$

$$\text{Substituindo os valores, } \frac{\|\delta x\|}{\|x\|} \leq 102 \times \frac{0,1}{3} \Rightarrow \frac{\|\delta x\|}{\|x\|} \leq 3,4$$

Uma expliação mais detalhada desse limite superior do erro pode ser encontrada no tópico 2.9.3 - Sensibilidade da solução- (páginas 115 e 116) do livro Algoritmos Numéricos do professor Frederico. É aconselhável estudar antes o tópico 2.1.4 -Normas- (páginas 39, 40, 41 e 42) para entender as diferentes normas e quando uma norma é dita consistente.

5. Assinale **V** para verdadeiro ou **F** para falso e **justifique**:

() Toda matriz $A \in \mathbb{R}^{m \times n}$ possui um SVD.

Verdadeiro. Os valores e vetores singulares vem da decomposição espectral de $A^T A$, que sempre existe.

() Na decomposição SVD $A = U \Sigma V^T$, as colunas de U são ortogonais às linhas de V .

Falso. As colunas de U são ortogonais entre si e as colunas de V são ortogonais entre si.

() Se A é singular, pelo menos um dos autovalores de A é nulo.

Verdadeiro. Como $\det(A) = 0$ é igual ao produto dos seus autovalores, pelo menos um deles deve ser nulo.

6. Seja a matriz $C = \begin{bmatrix} 1 & -1 \\ 0 & 1 \\ 1 & 0 \\ -1 & 1 \end{bmatrix}$. Mostre que

$$U = \begin{bmatrix} -0.632 & 0.000 \\ 0.316 & -0.707 \\ -0.316 & -0.707 \\ 0.632 & 0.000 \end{bmatrix} \quad \Sigma = \begin{bmatrix} 2.236 & 0.000 \\ 0.000 & 1.000 \end{bmatrix} \quad V^T = \begin{bmatrix} -0.707 & 0.707 \\ -0.707 & -0.707 \end{bmatrix}$$

é o SVD de C . Para isso, você pode usar:

- a decomposição espectral $C^T C = V \Lambda V^T$ e encontrar U usando $C v_i = \sigma_i u_i \Rightarrow u_i = \frac{C v_i}{\sigma_i}$, **OU**
- o fato de que o SVD é único quando todos os valores singulares de uma matriz são não-degenerados (não aparecem com multiplicidade maior que 1) e não-nulos.

Solução 1. As linhas da matriz V^T (vetores singulares direitos de C) são os autovetores de $C^T C$ associados a autovalores não-nulos. Decompondo $C^T C = V \Lambda V^T$, temos

$$V = \begin{bmatrix} 0.707 & 0.707 \\ -0.707 & 0.707 \end{bmatrix} \quad \sigma_1 = \sqrt{5} = 2.236 \quad \sigma_2 = \sqrt{1} = 1.000.$$

Em seguida, calculamos $u_i = \frac{C v_i}{\sigma_i}$, obtendo

$$U = \begin{bmatrix} 0.632 & 0.000 \\ -0.316 & 0.707 \\ 0.316 & 0.707 \\ -0.632 & 0.000 \end{bmatrix}.$$

Embora os sinais apareçam trocados, este SVD é equivalente.

```
C = np.array([[1, -1], [0, 1], [1, 0], [-1, 1]])
Lambda, V = np.linalg.eig(C.T @ C)
print(Lambda)
print(V)
Sigma = np.sqrt(Lambda)
U = np.zeros((4, 2))
for i in range(2):
    U[:, i] = (C @ V[:, i]) / Sigma[i]
```

Solução 2. Como todos os valores singulares são não-nulos e tem multiplicidade 1, basta mostrar que U e V são matrizes ortornomais. Para isso, basta fazer $U U^T = \mathbb{I}_4$ e $V V^T = \mathbb{I}_2$. Logo, esta decomposição tem de ser o SVD.

7. Suponha que a matriz C acima denota a opinião de quatro usuários sobre dois sites na Internet (-1: negativa, 0: neutra, 1: positiva). Vamos identificar os pares de usuários mais semelhantes. Uma forma de medir a semelhança entre dois usuários representados pelos vetores u e v é calcular o cosseno do ângulo θ formado entre eles:

$$\cos(\theta) = \frac{u \cdot v}{\|u\| \|v\|}.$$

Identifique para cada vetor, o outro vetor com que ele mais se assemelha. Refaça as contas utilizando a matriz U . O que você observou?

Calculando a similaridade de cosseno para a matriz C , obtemos a matriz

$$\begin{pmatrix} 1.000 & -0.707 & 0.707 & -1.000 \\ -0.707 & 1.000 & 0.000 & 0.707 \\ 0.707 & 0.000 & 1.000 & -0.707 \\ -1.000 & 0.707 & -0.707 & 1.000 \end{pmatrix},$$

logo o vetor que mais se assemelha ao 1o. é o 3o., ao 2o. é o 4o., ao 3o. é o 1o., e ao 4o. é o 2o.

Calculando a similaridade de cosseno para a matriz C , obtemos a matriz

$$\begin{pmatrix} 1.000 & -0.408 & 0.408 & -1.000 \\ -0.408 & 1.000 & 0.667 & 0.408 \\ 0.408 & 0.667 & 1.000 & -0.408 \\ -1.000 & 0.408 & -0.408 & 1.000 \end{pmatrix},$$

logo o vetor que mais se assemelha ao 1o. é o 3o., ao 2o. é o 3o., ao 3o. é o 2o., e ao 4o. é o 2o.

Observamos que o ranking das similaridades em C não é preservado na matriz U .

8. Suponha que queremos adicionar informação sobre um novo usuário que tem opinião positiva sobre os dois sites $w = (1, 1)$ à matriz U , sem recalculando o SVD. Como seria a representação deste usuário?

Para isso teríamos que adicionar uma linha x^\top à U de forma que $x^\top \Sigma V^\top = (1, 1)$. Transpondo ambos os lados temos:

$$\begin{pmatrix} 0.707 & 0.707 \\ -0.707 & 0.707 \end{pmatrix} \begin{pmatrix} 2.236 & 0.000 \\ 0.000 & 1.000 \end{pmatrix} x = \begin{pmatrix} 1 \\ 1 \end{pmatrix}.$$

Resolvendo este sistema encontramos $x^\top = [0.000, -1.414]$.

9. Seja A uma matriz $m \times n$. O SVD reduzido de A retorna $U_{m \times k}$, $\Sigma_{k \times k}$ e $V_{k \times n}^\top$. Já o SVD truncado de posto $r < \min(m, n)$ retorna apenas as r primeiras colunas de U , os r maiores valores singulares de Σ e as r primeiras linhas de V^\top .

Uma propriedade importante do SVD truncado é que ele retorna a melhor aproximação A_r para uma matriz A dentre todas as matrizes de posto r , onde a qualidade da aproximação é medida por $\|A - A_r\|_F$, sendo $\|B\|_F = \sqrt{\sum_i \sum_j B_{i,j}^2}$ a norma de Frobenius de uma matriz B .

Nesta questão, vamos ver como a qualidade da aproximação aumenta com r . Primeiramente, vamos gerar uma matriz aleatória $A_{10 \times 8}$. Em seguida, vamos encontrar a decomposição SVD reduzida. Depois disso, vamos variar o número r de valores singulares considerados para encontrar aproximações A_r para, finalmente, calcular $\|A - A_r\|_F$. Você pode criar uma tabela com os erros ou um gráfico, se preferir.

Para facilitar a resolução deste problema, o código com algumas lacunas é fornecido a seguir.

```
import numpy as np
m = 10; n = 8

A = ??? # criar uma matriz aleatoria 10 x 8
U, Sigma, Vt = np.linalg.svd(A)

erro = np.zeros(n)
A_r = np.zeros((m,n))
for r in range(min(m,n)):
    # calcular a aproximacao A_r de posto r para A
    A_r += np.outer(??? * Sigma[r], ???)
    erro[r] = np.linalg.norm(???)

print(erro)

import numpy as np
m = 10; n = 8

A = np.random.rand(m,n) # criar uma matriz aleatoria 10 x 8
U, Sigma, Vt = np.linalg.svd(A)

erro = np.zeros(n)
```

```

A_r = np.zeros((m,n))
for r in range(min(m,n)):
    # calcular a aproximacao A_r de posto r para A
    A_r += np.outer(U[:,r] * Sigma[r], Vt[r,:])
    erro[r] = np.linalg.norm(A-A_r)

print(erro)

```

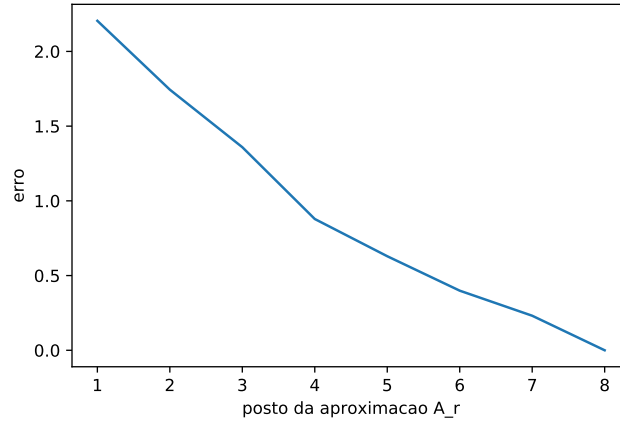


Figura 1: Solução da Questão 9: variação do erro conforme o posto da aproximação SVD.

10. Use a decomposição espectral de $A = \begin{pmatrix} 2 & -12 \\ 1 & -5 \end{pmatrix}$ em $A = Q\Lambda Q^{-1}$, onde $Q = \begin{pmatrix} 4 & 3 \\ 1 & 1 \end{pmatrix}$, $\Lambda = \begin{pmatrix} -1 & 0 \\ 0 & -2 \end{pmatrix}$ e $Q^{-1} = \begin{pmatrix} 1 & -3 \\ -1 & 4 \end{pmatrix}$, para calcular:

- (a) a inversa da matriz A , e

Temos que $A^{-1} = (Q\Lambda Q^{-1})^{-1} = Q\Lambda^{-1}Q^{-1}$. Como Λ é uma matriz diagonal, sua inversa é obtida invertendo-se os elementos da diagonal. Logo $A^{-1} = \begin{pmatrix} -2.5 & 6.0 \\ -0.5 & 1.0 \end{pmatrix}$

- (b) a potência A^{10} .

Temos que $A^{10} = Q\Lambda^{10}Q^{-1} = \begin{pmatrix} -3068 & 12276 \\ -1023 & 4093 \end{pmatrix}$.

- (c) o produto $A^{10}w$, por um vetor w de sua escolha e normalize o resultado para obter um vetor unitário. Qual a relação entre o resultado obtido e os autovetores de A ?

Observação: Se você quiser calcular a potência A^{10} para conferir sua solução do item b, você deve multiplicar a matriz 10 vezes ou usar `np.linalg.matrix_power(A,10)`. É errado fazer `A**10`, pois esta operação na verdade retorna uma matriz onde cada elemento de A está elevado a 10.

Vamos escolher $w = [1, 1]^T$, mas qualquer escolha onde uma coordenada não seja muito maior que a outra deve funcionar também. Nesse caso, o resultado obtido é $A^{10}w = [92083070]^T$. Note que isso é aproximadamente $3070 q_2$, onde q_2 é o autovetor relativo ao maior autovalor em módulo (i.e., -2). A explicação teórica é a seguinte. Sejam c_1 e c_2 os coeficientes tais que $w = c_1 q_1 + c_2 q_2$. Logo, tempos

$$\begin{aligned}
 A^k w &= A^k (c_1 q_1 + c_2 q_2) = c_1 A^k q_1 + c_2 A^k q_2 \\
 &= c_1 \lambda_1^k q_1 + c_2 \lambda_2^k q_2.
 \end{aligned}$$

Como $|\lambda_2^k| = 2^{10} \gg 1^{10} = |\lambda_1^k|$, $A^k w$ é aproximadamente um múltiplo de q_2 .